Apunte completo de procesos estocásticos

Cadenas de Markov, procesos de Poisson y campos aleatorios de Markov

Síntesis de estudio basada en los siete PDF del curso

3 de octubre de 2026

Índice

1. Panorama y notación **2**

2. Cadenas de Markov en tiempo discreto **2**

2.1. Propiedad de Markov y evolución . . . 2
2.2. Accesibilidad, comunicación y clases . . . 2
2.3. Primeras visitas y recurrencia . . . 3
2.4. Periodo . . . 4
2.5. Distribuciones invariantes y tiempos medios de recurrencia . . . 4
2.6. Teorema de convergencia y diferencia con invariancia . . . 5
2.7. Plantilla de clasificación completa . . . 5
2.8. Cadena de dos estados: fórmula explícita para P^n . . . 5

3. Proceso de Poisson temporal **6**

3.1. Definiciones constructiva y por incrementos . . . 6
3.2. Distribución del conteo y momentos . . . 7
3.3. Tiempos de llegada: distribución gamma . . . 7
3.4. Pérdida de memoria . . . 7
3.5. Independencia de incrementos y condicionamiento . . . 8
3.6. Superposición y asignación de tipos . . . 8
3.7. Poisson no homogéneo . . . 8
3.8. Proceso de Poisson compuesto . . . 9
3.9. Receta para ejercicios numéricos de Poisson . . . 9

4. Procesos de Poisson en el espacio **10**

5. Campos aleatorios de Markov e Ising **10**

5.1. Campo espacial y propiedad local 10
5.2. Modelo de Ising 11
5.3. Denoising como inferencia bayesiana 11

6. Conexiones, comprobaciones y errores frecuentes **12**

7. Formulario de consulta **13**

8. Fuentes integradas **13**

1. Panorama y notación

Este apunte reúne los conceptos, resultados y procedimientos de los documentos sobre cadenas de Markov, clasificación de estados, proceso de Poisson y campos aleatorios de Markov. El hilo conductor es modelar dependencia de dos maneras distintas:

- En una cadena de Markov, el índice es el tiempo y el estado actual resume la información relevante del pasado.
- En un campo aleatorio de Markov, el índice es un sitio espacial y el valor de un sitio queda condicionado localmente por sus vecinos.
- En un proceso de Poisson, se cuenta cuántos eventos aparecen en intervalos de tiempo o regiones del espacio.

En una cadena discreta, X_n es el estado en el paso n, S es el espacio de estados y

$$p_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i), \qquad p_{ij}^{(n)} = \mathbb{P}(X_n = j \mid X_0 = i).$$

La matriz de transición $P = (p_{ij})$ es estocástica por filas. Se usa $P^0 = I$ y $P^n = (p_{ij}^{(n)})$. Los vectores de distribución se escriben como vectores fila, de modo que una distribución inicial μ evoluciona según μP^n.

En un proceso de Poisson, N_t es el número de eventos hasta t, T_n es el tiempo entre el evento $n-1$ y el evento n, y $W_n = T_1 + \cdots + T_n$ es el instante de la n-ésima llegada. Estas dos últimas variables no son lo mismo: T_n es un interarribo; W_n es un tiempo acumulado.

2. Cadenas de Markov en tiempo discreto

2.1. Propiedad de Markov y evolución

Una cadena homogénea satisface

$$\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1}, \ldots, X_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i) = p_{ij}.$$

La homogeneidad significa que las probabilidades p_{ij} no dependen de n. La ecuación de Chapman–Kolmogórov expresa que las probabilidades de transición de varios pasos se obtienen multiplicando matrices:

$$p_{ij}^{(n+m)} = \sum_{k \in S} p_{ik}^{(n)} p_{kj}^{(m)}, \qquad P^{n+m} = P^n P^m.$$

2.2. Accesibilidad, comunicación y clases

El estado j es accesible desde i, escrito $i \to j$, si existe $n \geq 0$ tal que $p_{ij}^{(n)} > 0$. Los estados se comunican, $i \leftrightarrow j$, si cada uno es accesible desde el otro. La comunicación es reflexiva, simétrica y transitiva; por ello divide S en clases disjuntas.

Una clase es *cerrada* si no hay transiciones desde ella hacia estados externos. Una clase que sí tiene una flecha saliente es abierta. La cadena es *irreducible* precisamente cuando todo el espacio de estados constituye una sola clase de comunicación. Un estado i es absorbente cuando $p_{ii} = 1$.

Cómo hallar las clases en una matriz finita.

1. En cada fila i, anotar todos los destinos j con $p_{ij} > 0$ y dibujar las flechas.
2. Buscar caminos en ambos sentidos. Los estados mutuamente alcanzables forman una clase.
3. Revisar si alguna flecha sale de cada clase; esto decide si es cerrada.
4. No confundir una flecha de ida con comunicación: para $i \leftrightarrow j$ también debe existir un camino de vuelta.

2.3. Primeras visitas y recurrencia

El tiempo de primera visita a j, partiendo de i, es

$$\tau_{ij} = \text{ínf}\{n \geq 0 : X_n = j \mid X_0 = i\}.$$

Para el retorno a i se exige un paso positivo:

$$\tau_i = \text{ínf}\{n \geq 1 : X_n = i \mid X_0 = i\}.$$

Se define $f_{ij}(n) = \mathbb{P}(\tau_{ij} = n \mid X_0 = i)$ y $f_{ij} = \sum_{n\geq 1} f_{ij}(n)$ como probabilidad de visitar alguna vez j desde i. En particular, f_{ii} es la probabilidad de regresar alguna vez a i.

El estado i es recurrente si $f_{ii} = 1$ y transitorio si $f_{ii} < 1$. La recurrencia y la transitoriedad son propiedades de clase: todos los estados de una misma clase tienen el mismo tipo.

Criterio de recurrencia y su demostración

Partiendo de i, sea N_i el número total de retornos a i después del instante inicial. La propiedad fuerte de Markov en cada retorno da

$$\mathbb{P}(N_i \geq k) = f_{ii}^k, \qquad k \geq 1.$$

Para una variable entera no negativa, su esperanza es la suma de las probabilidades de cola. Por tanto,

$$\mathbb{E}(N_i) = \sum_{k\geq 1} f_{ii}^k = \begin{cases} \dfrac{f_{ii}}{1 - f_{ii}}, & f_{ii} < 1, \\ +\infty, & f_{ii} = 1. \end{cases}$$

Por otro lado, escribiendo $N_i = \sum_{n\geq 1} \mathbf{1}_{\{X_n = i\}}$ y usando que los sumandos son no negativos,

$$\mathbb{E}(N_i) = \sum_{n\geq 1} \mathbb{P}(X_n = i \mid X_0 = i) = \sum_{n\geq 1} p_{ii}^{(n)}.$$

Así se obtiene el criterio

$$\boxed{i \text{ recurrente} \iff \sum_{n\geq 1} p_{ii}^{(n)} = \infty, \qquad i \text{ transitorio} \iff \sum_{n\geq 1} p_{ii}^{(n)} < \infty.}$$

La serie mide el número esperado de retornos. Si $f_{ii} = 1$, habrá infinitos retornos casi seguramente; si $f_{ii} < 1$, el número esperado de retornos es finito.

Toda clase cerrada y finita es recurrente positiva. En consecuencia, toda cadena finita e irreducible es recurrente positiva. Un estado recurrente puede ser recurrente nulo si el retorno ocurre casi seguramente pero su esperanza es infinita; la caminata simétrica en $\mathbb{Z}$ es el ejemplo clásico.

2.4. Periodo

El periodo de un estado es el máximo común divisor de los pasos positivos en los que puede volver:

$$d(i) = \mathrm{mcd}\{n \geq 1 : p_{ii}^{(n)} > 0\}.$$

Si no hay retorno posible, se adopta $d(i) = 0$. El estado es aperiódico si $d(i) = 1$. Estados comunicantes tienen el mismo periodo, así que el periodo es una propiedad de clase.

Reglas prácticas:

- Si $p_{ii} > 0$, existe un retorno en un paso y $d(i) = 1$.
- Si todos los ciclos de retorno tienen longitud par y al menos un retorno de longitud 2 es posible, el periodo es 2.
- Para decidir el periodo, se necesita el máximo común divisor de las longitudes posibles, no solamente la longitud de un ciclo observado.

Por ejemplo, una cadena que alterna entre conjuntos de estados de paridad opuesta sólo puede regresar a un estado en tiempos pares: su periodo es 2. Si además puede regresar en dos pasos y en tres, el máximo común divisor es 1 y la clase es aperiódica.

2.5. Distribuciones invariantes y tiempos medios de recurrencia

Una distribución $\pi = (\pi_j)$ es invariante si

$$\pi_j \geq 0, \qquad \sum_j \pi_j = 1, \qquad \pi P = \pi.$$

La ecuación en la coordenada j es $\pi_j = \sum_i \pi_i p_{ij}$; usa la columna j de P. Es frecuente equivocarse usando las filas en este cálculo.

El tiempo medio de recurrencia de un estado recurrente es

$$\mu_i = \mathbb{E}(\tau_i \mid X_0 = i).$$

Se llama recurrente positivo si $\mu_i < \infty$ y recurrente nulo si $\mu_i = \infty$. Para una cadena irreducible y recurrente positiva existe una única distribución invariante y

$$\boxed{\pi_i = \frac{1}{\mu_i}, \qquad \mu_i = \frac{1}{\pi_i}.}$$

La interpretación de π_i es la fracción de tiempo de largo plazo que se pasa en i, cuando se consideran promedios temporales. Esta interpretación no garantiza por sí sola que $p_{ij}^{(n)}$ converja.

En una cadena reducible pueden existir varias clases cerradas y, por ello, múltiples distribuciones invariantes. Cada clase recurrente cerrada aporta su distribución estacionaria; las combinaciones convexas de ellas también son invariantes. Los estados transitorios tienen masa cero bajo cualquier distribución invariante de una cadena finita.

Resolución segura de $\pi P = \pi$.

1. Escribir las ecuaciones coordenada por coordenada, usando las columnas de P.

2. Añadir la condición $\sum_i \pi_i = 1$.
3. Resolver y sustituir en una ecuación que no se haya usado para despejar.
4. Si hay varias clases recurrentes, resolver dentro de cada clase cerrada y formar después las mezclas convexas.

2.6. Teorema de convergencia y diferencia con invariancia

Si una cadena es irreducible, recurrente positiva y aperiódica, entonces para todo estado inicial i y destino j,

$$\lim_{n\to\infty} p_{ij}^{(n)} = \pi_j,$$

donde π es la única distribución invariante. En cadenas finitas, irreducibilidad ya implica recurrencia positiva; por tanto, basta comprobar además la aperiodicidad.

Las tres hipótesis tienen papeles distintos:

- Sin irreducibilidad puede haber varias clases cerradas y límites que dependen del estado inicial.
- Sin aperiodicidad puede haber oscilación aunque exista una única distribución invariante.
- El teorema es suficiente, no necesario: una cadena reducible también puede converger, por ejemplo si todos los estados acaban absorbidos en un único estado.

Ejemplo extremo: $P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$. La distribución $(1/2, 1/2)$ es invariante, pero la cadena alterna determinísticamente y $p_{00}^{(n)}$ toma sucesivamente los valores $1, 0, 1, 0, \ldots$. No existe límite.

2.7. Plantilla de clasificación completa

Ante una matriz finita, conviene entregar la respuesta en este orden:

1. Diagrama de transición y lista de destinos positivos por fila.
2. Clases de comunicación; marcar cada una como cerrada o abierta e indicar irreducibilidad.
3. Recurrente/transitorio. En una cadena finita, las clases cerradas son recurrentes positivas; las abiertas contienen estados transitorios.
4. Periodo de cada clase, calculando el máximo común divisor de los tiempos de retorno.
5. Distribuciones invariantes y tiempos medios de recurrencia de los estados recurrentes.
6. Verificación separada de las tres hipótesis del teorema de convergencia y conclusión sobre los límites.

2.8. Cadena de dos estados: fórmula explícita para P^n

Considérese $S = \{0, 1\}$ y

$$P = \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix}, \qquad a, b > 0.$$

El parámetro a es la probabilidad de pasar de 0 a 1 y b la de pasar de 1 a 0. Sea $\lambda = 1 - a - b$. Definimos

$$\Pi = \frac{1}{a+b}\begin{pmatrix} b & a \\ b & a \end{pmatrix}, \qquad R = \frac{1}{a+b}\begin{pmatrix} a & -a \\ -b & b \end{pmatrix}.$$

Entonces $\Pi + R = I$, $\Pi P = \Pi$ y $RP = \lambda R$. La última igualdad puede verificarse multiplicando las matrices. Por inducción sobre n,

$$\boxed{P^n = \Pi + \lambda^n R.}$$

La base $n = 0$ es $P^0 = I = \Pi + R$. Si la identidad vale para n, entonces

$$P^{n+1} = P^n P = \Pi P + \lambda^n R P = \Pi + \lambda^{n+1} R.$$

Como $\pi = (b/(a+b), a/(a+b))$,

$$P^n = \begin{pmatrix} \dfrac{b}{a+b} + \dfrac{a}{a+b}\lambda^n & \dfrac{a}{a+b} - \dfrac{a}{a+b}\lambda^n \\ \dfrac{b}{a+b} - \dfrac{b}{a+b}\lambda^n & \dfrac{a}{a+b} + \dfrac{b}{a+b}\lambda^n \end{pmatrix}.$$

Si $a, b \in (0,1)$, entonces $-1 < 1 - a - b < 1$, de modo que $\lambda^n \to 0$ y ambas filas convergen a π. Los tiempos medios son $\mu_0 = (a+b)/b$ y $\mu_1 = (a+b)/a$.

Ejemplo. Si $a = 0.3$ y $b = 0.2$, entonces $\lambda = 0.5$, $\pi = (0.4, 0.6)$, $\mu_0 = 2.5$ y $\mu_1 = 5/3$. Además,

$$P^3 = \begin{pmatrix} 0.475 & 0.525 \\ 0.350 & 0.650 \end{pmatrix}.$$

Si $a = b = 1$, en cambio, $\lambda = -1$: la cadena alterna entre los estados, el periodo es 2 y no hay límite, aunque $(1/2, 1/2)$ siga siendo invariante. En los casos de borde con estados absorbentes o transitorios hay que reclasificar la cadena; no se deben aplicar fórmulas de recurrencia que requieren que los estados sean recurrentes.

3. Proceso de Poisson temporal

3.1. Definiciones constructiva y por incrementos

Un proceso de conteo registra eventos sucesivos. Para un proceso de Poisson homogéneo de tasa $\lambda > 0$, los interarribos $T_1, T_2, \ldots$ son independientes e idénticamente distribuidos como $\mathrm{Exp}(\lambda)$, cuya densidad y cola son

$$f_T(t) = \lambda e^{-\lambda t}, \quad \mathbb{P}(T > t) = e^{-\lambda t}, \quad \mathbb{E}(T) = \frac{1}{\lambda}, \quad \mathrm{Var}(T) = \frac{1}{\lambda^2}, \qquad t \geq 0.$$

Con $W_n = T_1 + \cdots + T_n$, el conteo es

$$N_t = \max\{n \geq 0 : W_n \leq t\}, \qquad W_0 = 0.$$

Equivalentemente, $N_0 = 0$, los incrementos son independientes y

$$N_{s+t} - N_s \sim \mathrm{Poisson}(\lambda t), \qquad s \geq 0, \quad t > 0.$$

Las trayectorias son no decrecientes, constantes entre eventos, continuas por la derecha y sus saltos tienen tamaño uno. El parámetro λ es la tasa media de eventos por unidad de tiempo.

3.2. Distribución del conteo y momentos

Para cada $t \geq 0$,

$$\boxed{\mathbb{P}(N_t = k) = e^{-\lambda t}\frac{(\lambda t)^k}{k!}, \qquad k = 0, 1, 2, \ldots}$$

Por ello

$$N_t \sim \text{Poisson}(\lambda t), \qquad \mathbb{E}(N_t) = \text{Var}(N_t) = \lambda t.$$

En un intervalo $(s, s+t]$ se reemplaza t por la longitud del intervalo. Para una cola, por ejemplo,

$$\mathbb{P}(N_t \geq r) = 1 - \sum_{k=0}^{r-1} e^{-\lambda t}\frac{(\lambda t)^k}{k!}.$$

3.3. Tiempos de llegada: distribución gamma

W_n es suma de n exponenciales independientes de tasa λ; por tanto tiene distribución Erlang, un caso de la gamma:

$$W_n \sim \text{Gamma}(n, \lambda), \qquad f_{W_n}(w) = \frac{\lambda^n w^{n-1} e^{-\lambda w}}{(n-1)!}, \quad w > 0.$$

Sus momentos son

$$\mathbb{E}(W_n) = \frac{n}{\lambda}, \qquad \text{Var}(W_n) = \frac{n}{\lambda^2}.$$

El puente más útil entre conteos y esperas es

$$\boxed{\{W_n \leq t\} = \{N_t \geq n\}.}$$

También,

$$\mathbb{P}(W_n \leq t) = 1 - e^{-\lambda t}\sum_{k=0}^{n-1}\frac{(\lambda t)^k}{k!}.$$

Un tramo $W_m - W_n = T_{n+1} + \cdots + T_m$ es gamma$(m-n, \lambda)$ si $m > n$.

3.4. Pérdida de memoria

La exponencial satisface

$$\mathbb{P}(T > s + t \mid T > s) = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(T > t).$$

Por tanto, si ya transcurrió un tiempo s sin eventos, la espera residual conserva la ley Exp(λ) y su media sigue siendo $1/\lambda$. La edad de la espera no la hace más cercana ni más lejana.

3.5. Independencia de incrementos y condicionamiento

Para $0 < s < t$, los conteos N_s y $N_t - N_s$ son independientes, con leyes Poisson(λs) y Poisson($\lambda(t-s)$). En consecuencia,

$$\mathrm{Cov}(N_s, N_t) = \mathrm{Cov}(N_s, N_s + N_t - N_s) = \mathrm{Var}(N_s) = \lambda s,$$

y

$$\mathrm{Corr}(N_s, N_t) = \frac{\lambda s}{\sqrt{(\lambda s)(\lambda t)}} = \sqrt{\frac{s}{t}}.$$

Condicionado al total hasta t, el reparto temporal es binomial:

$$\boxed{N_s \mid (N_t = n) \sim \mathrm{Bin}\left(n, \frac{s}{t}\right).}$$

Por tanto,

$$\mathbb{E}(N_s \mid N_t) = \frac{s}{t} N_t, \qquad \mathbb{P}(W_1 \le s \mid N_t = 1) = \frac{s}{t}.$$

Más generalmente, dados $N_t = n$, los n instantes de llegada tienen la distribución de n variables uniformes independientes en $(0, t)$ ordenadas de menor a mayor. La tasa λ desaparece de esta distribución condicional.

3.6. Superposición y asignación de tipos

Si N_t y M_t son procesos independientes de tasas λ_1 y λ_2, entonces $N_t + M_t$ es Poisson de tasa $\lambda_1 + \lambda_2$. En particular,

$$\mathbb{P}(N_t + M_t = k) = e^{-(\lambda_1+\lambda_2)t} \frac{((\lambda_1 + \lambda_2)t)^k}{k!}.$$

Condicionado a un total de k eventos,

$$N_t \mid (N_t + M_t = k) \sim \mathrm{Bin}\left(k, \frac{\lambda_1}{\lambda_1 + \lambda_2}\right).$$

La probabilidad de que el próximo evento provenga de la fuente 1 también es $\lambda_1/(\lambda_1 + \lambda_2)$. La espera hasta el primer evento de cualquiera de las dos fuentes es exponencial de tasa suma.

3.7. Poisson no homogéneo

La tasa puede depender del tiempo. Si la intensidad es $\lambda(u) \ge 0$, se define la intensidad acumulada

$$m(t) = \int_0^t \lambda(u)\, du.$$

El proceso conserva incrementos independientes y

$$N_t - N_s \sim \mathrm{Poisson}\big(m(t) - m(s)\big), \qquad \mathbb{E}(N_t - N_s) = \mathrm{Var}(N_t - N_s) = m(t) - m(s).$$

En particular, $N_t \sim \mathrm{Poisson}(m(t))$ y la supervivencia de la primera llegada es

$$\mathbb{P}(W_1 > t) = \mathbb{P}(N_t = 0) = e^{-m(t)}.$$

La pérdida de memoria, en general, desaparece:

$$\mathbb{P}(W_1 > s+u \mid W_1 > s) = \exp\big(-(m(s+u)-m(s))\big),$$

que no tiene por qué coincidir con $e^{-m(u)}$.

Ejemplo. Para $\lambda(t) = 2t$, se tiene $m(t) = t^2$. Entonces

$$N_2 \sim \text{Poisson}(4), \qquad N_3 - N_1 \sim \text{Poisson}(9-1) = \text{Poisson}(8), \qquad \mathbb{P}(W_1 > t) = e^{-t^2}.$$

La mediana de W_1 resuelve $e^{-t^2} = 1/2$, así que es $\sqrt{\log 2}$. Condicionado a no haber llegado a la hora 1, la probabilidad de que la primera llegada espere más de 0.5 horas adicionales es $e^{-(2.25-1)} = e^{-1.25}$, no $e^{-0.25}$.

3.8. Proceso de Poisson compuesto

Sean $Y_1, Y_2, \ldots$ i.i.d., independientes del proceso de conteo, y sea

$$X_t = \sum_{i=1}^{N_t} Y_i,$$

con suma cero cuando $N_t = 0$. Si Y tiene segundo momento finito y $N_t \sim \text{Poisson}(\lambda t)$,

$$\boxed{\mathbb{E}(X_t) = \lambda t \mathbb{E}(Y), \qquad \text{Var}(X_t) = \lambda t \mathbb{E}(Y^2).}$$

Para entender la varianza, se aplica la ley de varianza total:

$$\begin{aligned}\text{Var}(X_t) &= \mathbb{E}[\text{Var}(X_t \mid N_t)] + \text{Var}[\mathbb{E}(X_t \mid N_t)] \\ &= \mathbb{E}(N_t)\,\text{Var}(Y) + \text{Var}(N_t)(\mathbb{E}Y)^2 \\ &= \lambda t\big(\text{Var}(Y) + (\mathbb{E}Y)^2\big) = \lambda t \mathbb{E}(Y^2).\end{aligned}$$

No se debe sustituir $\text{Var}(Y)$ por $\mathbb{E}(Y^2)$ en la fórmula: ambas fuentes de variabilidad, el tamaño de cada monto y el número aleatorio de eventos, importan.

Ejemplo. Si hay 5 siniestros esperados por mes, cada uno con media 1000 y desviación estándar 600, entonces $\mathbb{E}(Y^2) = 600^2 + 1000^2 = 1\,360\,000$. En seis meses, $\mathbb{E}(X) = 30\,000$ y $\text{Var}(X) = 40\,800\,000$ dólares cuadrados.

3.9. Receta para ejercicios numéricos de Poisson

1. Fijar una unidad de tiempo común para λ y t.
2. Calcular el parámetro del conteo: $\theta = \lambda t$, o $\theta = m(t) - m(s)$ si la tasa varía.
3. Traducir el evento: «al menos r» es complemento de «a lo más $r-1$»; $W_n \le t$ equivale a $N_t \ge n$.
4. Elegir conteo Poisson, espera exponencial/gamma, incremento independiente o suma compuesta.
5. Mantener forma exacta y unidades; verificar que las probabilidades están en $[0,1]$ y las varianzas son no negativas.

Ejemplo breve. Con $\lambda = 6$ llamadas por hora,

$$\mathbb{P}(N_1 = 4) = e^{-6}\frac{6^4}{4!}, \qquad \mathbb{P}(N_{1/2} \geq 2) = 1 - e^{-3}(1+3),$$

$$\mathbb{P}(W_1 > 20 \text{ min}) = e^{-6/3} = e^{-2}.$$

Además $W_5 \sim \text{Gamma}(5, 6)$, con media 5/6 horas y varianza 5/36 horas cuadradas.

4. Procesos de Poisson en el espacio

Ahora los eventos son puntos de una región $A \subseteq \mathbb{R}^2$ y $N(B)$ cuenta los puntos que caen en $B \subseteq A$. Un proceso de Poisson espacial homogéneo de intensidad λ cumple

$$N(B) \sim \text{Poisson}(\lambda |B|),$$

y los conteos de regiones disjuntas son independientes. La intensidad es el número medio de puntos por unidad de área.

Condicionado a que $N(A) = n$, las ubicaciones de los n puntos son independientes y uniformes en A. Si la intensidad depende de la ubicación, se usa $\lambda(x)$ y el parámetro de $N(B)$ es $\int_B \lambda(x)\, dx$.

Distancia al punto más cercano. Sea R la distancia desde el origen al punto más próximo en un proceso homogéneo en el plano. Para $x \geq 0$,

$$\mathbb{P}(R^2 > x) = \mathbb{P}(N(B(0, \sqrt{x})) = 0) = e^{-\lambda \pi x}.$$

Luego $R^2 \sim \text{Exp}(\lambda\pi)$. Esta identidad se debe a que el área del disco de radio $\sqrt{x}$ es πx.

La homogeneidad espacial es una hipótesis fuerte: significa densidad media constante y ausencia de atracción o repulsión entre puntos, una vez fijada el área. Si el entorno, la elevación o la densidad de población cambia, suele ser más razonable un modelo no homogéneo.

5. Campos aleatorios de Markov e Ising

5.1. Campo espacial y propiedad local

Sea S un conjunto finito de sitios y X_s una variable aleatoria en cada sitio. La colección $X = \{X_s : s \in S\}$ es un campo aleatorio; una realización $x = (x_s)$ es una configuración. A cada s se le asigna un conjunto de vecinos $N(s)$, normalmente simétrico: $t \in N(s)$ si y sólo si $s \in N(t)$.

El campo tiene la propiedad de Markov espacial cuando, para cada sitio s,

$$\mathbb{P}(X_s = x_s \mid X_t = x_t,\ t \neq s) = \mathbb{P}(X_s = x_s \mid X_t = x_t,\ t \in N(s)).$$

Conocer los vecinos hace irrelevante, para predecir el sitio, el resto del campo. La vecindad forma parte de la definición del modelo: en una imagen se pueden usar cuatro vecinos ortogonales o agregar las cuatro diagonales.

5.2. Modelo de Ising

En el modelo de Ising, $X_s \in \{-1, +1\}$ y sitios vecinos tienden a tomar el mismo valor. Con parámetro $\beta \geq 0$, la probabilidad condicional local es

$$\boxed{\mathbb{P}(X_s = +1 \mid X_t, t \in N(s)) = \frac{1}{1 + \exp\left(-2\beta \sum_{t \in N(s)} X_t\right)}.}$$

Es una regresión logística cuyo predictor es la suma de los valores vecinos.

- Si $\beta = 0$, el sitio vale $+1$ con probabilidad $1/2$, sin influencia vecinal.
- Si la suma vecinal es positiva, la mayoría favorece $+1$; si es negativa, favorece -1.
- Si los vecinos se equilibran, la probabilidad es $1/2$.
- Al crecer β, aumenta la tendencia a imitar a los vecinos.

Para cuatro vecinos y $\beta = 0.8$, las probabilidades aproximadas de que el sitio sea $+1$ son:

suma vecinal	4	2	0	-2	-4
$\mathbb{P}(X_s = +1 \mid \text{vecinos})$	0.998	0.961	0.500	0.039	0.002

En un grafo finito sin campo externo, la distribución conjunta asociada tiene la forma de Gibbs

$$\mathbb{P}(X = x) = \frac{1}{Z(\beta)} \exp\left(\beta \sum_{\{s,t\} \in E} x_s x_t\right),$$

donde cada arista no dirigida se cuenta una vez y $Z(\beta)$ normaliza las probabilidades. Las configuraciones homogéneas se favorecen cuando $\beta > 0$. La constante Z involucra una suma sobre todas las configuraciones, que crece exponencialmente con el número de sitios.

5.3. Denoising como inferencia bayesiana

En una imagen binaria, $x_s \in \{-1, +1\}$ representa papel/tinta o dos clases verdaderas y y_s es el dato observado. Si

$$Y_s \mid X_s = x_s \sim \mathcal{N}(x_s, \sigma^2)$$

independientemente entre sitios, el prior de Ising favorece regiones localmente coherentes y la verosimilitud modela el ruido del escáner. Por Bayes,

$$\mathbb{P}(x \mid y) \propto \mathbb{P}(y \mid x)\mathbb{P}(x).$$

La condicional posterior de un sitio es

$$\boxed{\mathbb{P}(X_s = +1 \mid \text{vecinos}, y_s) = \frac{1}{1 + \exp\left[-2\left(\beta \sum_{t \in N(s)} X_t + \dfrac{y_s}{\sigma^2}\right)\right]}.}$$

El primer término del predictor es la evidencia del vecindario; el segundo, la evidencia local del escaneo. La decisión MAP local favorece $+1$ cuando

$$y_s > -\beta\sigma^2 \sum_{t \in N(s)} X_t.$$

Así, un dato observado ligeramente positivo no basta necesariamente para etiquetar tinta si todos los vecinos apoyan papel. En el ejemplo del material, la decisión independiente pixel a pixel tenía 20.2 % de error, frente a 4.0 % al incorporar los vecinos; es una mejora de ese ejemplo, no una garantía universal.

Las mismas ideas se aplican a clasificación de imágenes satelitales o médicas, mapas de enfermedad y ecología espacial: la dependencia local permite estabilizar sitios ruidosos o con poca información.

6. Conexiones, comprobaciones y errores frecuentes

Confusión	**Distinción correcta**
Invariante frente a límite	$\pi P = \pi$ dice que partir de π conserva la ley. Que P^n converja desde cada estado requiere además las hipótesis de irreducibilidad, recurrencia positiva y aperiodicidad.
Filas frente a columnas	P actúa sobre distribuciones fila por la derecha. La coordenada j de πP usa la columna j de P.
Clase cerrada frente a irreducible	Puede haber varias clases cerradas en una cadena reducible. La irreducibilidad exige una sola clase para todo el espacio.
Periodo frente a ciclo visible	Se calcula el máximo común divisor de todas las longitudes de retorno posibles. Un lazo garantiza periodo 1.
T_n frente a W_n	T_n es el interarribo n; $W_n = \sum_{k=1}^{n} T_k$ es el instante de la llegada n.
Poisson frente a gamma	N_t cuenta eventos y es Poisson; W_n mide el instante de la llegada n y es gamma/Erlang.
Tasa frente a probabilidad	λ tiene unidades de eventos/tiempo. Siempre convertir t a la unidad de λ antes de usar λt.
Varianza compuesta	$\operatorname{Var}(X_t) = \lambda t \mathbb{E}(Y^2)$, no $\lambda t \operatorname{Var}(Y)$. La aleatoriedad del conteo también aporta variabilidad.
Poisson homogéneo frente a no homogéneo	En el segundo, la media de un incremento depende del intervalo mediante $m(t) - m(s)$, no sólo de su longitud. En general no hay falta de memoria.

Chequeos rápidos antes de entregar una solución.

- Cada fila de una matriz de transición suma uno y todas sus entradas son no negativas.
- Una distribución suma uno, es no negativa y satisface $\pi P = \pi$.
- Un límite propuesto debe ser compatible con la periodicidad y con las clases cerradas accesibles.
- En Poisson, θ debe ser adimensional; una cola «al menos» debe incluir todos los valores desde el umbral.
- En una suma compuesta, las unidades de $\mathbb{E}(X_t)$ y $\operatorname{Var}(X_t)$ son las del monto y su cuadrado.
- Para un proceso espacial homogéneo, el parámetro de una región es intensidad por área.

7. Formulario de consulta

Transición de n pasos:	$P^{n+m} = P^n P^m$,
Recurrencia:	i recurrente $\iff \sum_{n\geq 1} p_{ii}^{(n)} = \infty$,
Periodo:	$d(i) = \mathrm{mcd}\{n \geq 1 : p_{ii}^{(n)} > 0\}$,
Invariante:	$\pi P = \pi, \qquad \pi_i = 1/\mu_i$ (irreducible positiva),
Convergencia:	irreducible + positiva recurrente + aperiódica,
Exponencial:	$\mathbb{P}(T > t) = e^{-\lambda t}, \quad \mathbb{E}T = 1/\lambda, \quad \mathrm{Var}\, T = 1/\lambda^2$,
Poisson:	$N_t \sim \mathrm{Poisson}(\lambda t), \quad \mathbb{P}(N_t = k) = e^{-\lambda t}(\lambda t)^k/k!$,
Gamma:	$W_n \sim \mathrm{Gamma}(n, \lambda), \quad \mathbb{E}W_n = n/\lambda, \quad \mathrm{Var}\, W_n = n/\lambda^2$,
Puente conteo-espera:	$\{W_n \leq t\} = \{N_t \geq n\}$,
Condicional temporal:	$N_s \mid N_t = n \sim \mathrm{Bin}(n, s/t)$,
Superposición:	$\lambda_{\mathrm{total}} = \sum_r \lambda_r$,
No homogéneo:	$m(t) = \int_0^t \lambda(u)\, du, \quad N_t - N_s \sim \mathrm{Poisson}(m(t) - m(s))$,
Poisson compuesto:	$\mathbb{E}X_t = \lambda t \mathbb{E}Y, \quad \mathrm{Var}\, X_t = \lambda t \mathbb{E}(Y^2)$,
Poisson espacial:	$N(B) \sim \mathrm{Poisson}(\lambda \lvert B \rvert), \quad R^2 \sim \mathrm{Exp}(\lambda\pi)$,
Ising local:	$\mathbb{P}(X_s = +1 \mid \text{vecinos}) = \{1 + e^{-2\beta \sum_{t\in N(s)} X_t}\}^{-1}$.

8. Fuentes integradas

El contenido se sintetizó a partir de los documentos proporcionados en el espacio de trabajo:

1. *Guia_I2_PasoAPaso_Cadenas_y_Poisson_261003_165712.pdf.*
2. *Ejercicios_repaso3.pdf.*
3. *formulario_control2.pdf.*
4. *clasificacion de estados en cadenas de Markov.pdf.*
5. *complemento_demostraciones.pdf.*
6. *proceso_poisson-2.pdf.*
7. *Campos aleatorios de Markov.pdf.*

Las fórmulas y explicaciones están reorganizadas y redactadas como material de estudio; los ejemplos numéricos se usan para ilustrar los procedimientos y no sustituyen las hipótesis de cada teorema.