Procesos markovianos espaciales

Procesos Estocásticos

Alfredo Alegría

Facultad de Matemáticas, Pontificia Universidad Católica de Chile

Del tiempo al espacio

En una cadena de Markov el índice es el tiempo, y el futuro depende del pasado sólo a través del presente. Hay un orden natural entre los índices.

Cuando el índice es una ubicación del plano ese orden desaparece. Un pixel de una imagen, una comuna de un mapa o una parcela de un campo experimental tienen vecinos en todas las direcciones, y ninguno de ellos es el pasado.

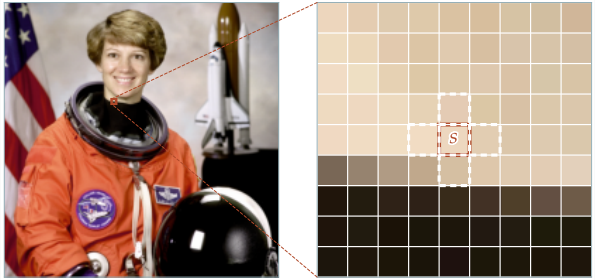
La idea se conserva reemplazando el pasado por el resto del espacio, y el presente por la vecindad.

Campos aleatorios y vecindades

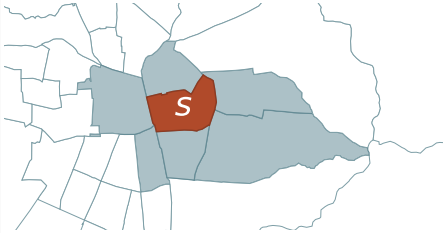
Se tiene un conjunto finito de sitios S y una variable aleatoria X_s en cada uno de ellos. La colección $X = \{X_s : \ s \in S\}$ se llama campo aleatorio, y una realización $x = (x_s)$ se llama configuración.

Cada sitio tiene asociado un conjunto de vecinos $N(s)$, con la condición natural de que si s es vecino de t, entonces t es vecino de s. La elección de la vecindad es parte del modelo.

Ejemplos de vecindades



En una imagen, cada sitio es un pixel y sus vecinos son los cuatro contiguos



En un mapa, cada sitio es una comuna y sus vecinas son las que comparten frontera

En una retícula también se usa la vecindad de ocho, que agrega las cuatro diagonales.

La propiedad de Markov espacial

Definición

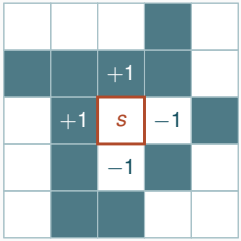
El campo X tiene la propiedad de Markov espacial si, para cada sitio s,

$$\mathbb{P}\big(X_s = x_s \mid x_t,\ t \neq s\big) = \mathbb{P}\big(X_s = x_s \mid x_t,\ t \in N(s)\big).$$

Conocidos los valores de los vecinos, el resto del campo no aporta información adicional sobre el sitio. Un campo con esta propiedad se llama campo aleatorio de Markov.

Estas condicionales son el objeto que uno modela, porque describen directamente cómo se relaciona un sitio con su entorno.

El modelo de Ising



Cada sitio de una retícula toma uno de dos valores, $+1$ o -1, por ejemplo blanco y negro en una imagen.

La idea del modelo es simple. Cada sitio tiende a parecerse a sus vecinos, y la intensidad de esa tendencia la fija un parámetro $\beta \geq 0$.

Formalmente, la probabilidad de que el sitio s valga $+1$ crece con la suma de los valores de sus vecinos.

La regla local

La probabilidad condicional de un sitio, dados sus vecinos, es

$$\mathbb{P}\big(X_s = +1 \mid x_t,\ t \in N(s)\big) = \frac{1}{1 + \exp\{-2\beta \sum_{t \in N(s)} x_t\}},$$

que es una regresión logística cuya única covariable es la suma de los vecinos.

Con $\beta = 0$ el sitio es independiente de todo lo demás y vale $+1$ con probabilidad $1/2$. A medida que β crece, el sitio sigue cada vez más de cerca a la mayoría de sus vecinos.

La regla local en números

Sitio interior con cuatro vecinos y $\beta = 0{,}8$.

Vecinos en $+1$	$\sum_{t \in N(s)} x_t$	$\mathbb{P}(X_s = +1 \mid \text{vecinos})$
4	4	0,998
3	2	0,961
2	0	0,500
1	-2	0,039
0	-4	0,002

Cuando los vecinos están empatados el sitio decide al azar. Cuando hay mayoría, el sitio la sigue con alta probabilidad.

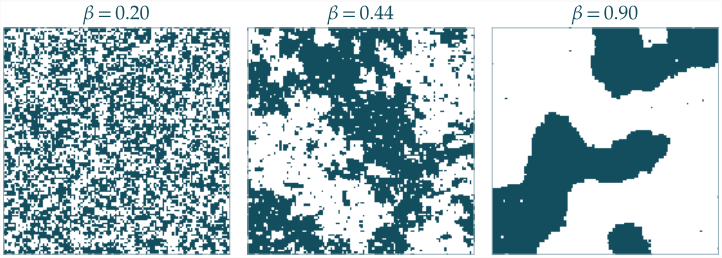
Comentario sobre la construcción

Las reglas locales anteriores provienen de una distribución conjunta para toda la configuración, en la que las configuraciones con muchos vecinos iguales son más probables.

Esa distribución existe y es única, lo que en este caso es un resultado clásico de la teoría. Lo relevante para la clase de hoy es que basta especificar el comportamiento local para tener un modelo espacial completo.

La distribución conjunta involucra una constante de normalización que suma sobre todas las configuraciones posibles, de modo que no se puede evaluar en la práctica. 

Realizaciones del modelo



Retícula de 120×120 sitios, simulada a partir de las reglas locales.

Con β pequeño el campo se ve como ruido independiente. Al aumentar β aparecen regiones extensas del mismo color, que es justamente lo que uno observa en imágenes reales.

Tres aplicaciones

- Imágenes y teledetección. Cada sitio es un pixel y se quiere asignarle una clase, como el tipo de cobertura de suelo en una imagen satelital, el tejido en una imagen médica o la tinta en un documento. Los pixeles vecinos suelen pertenecer a la misma clase, y eso permite corregir los errores del sensor.
- Mapas de enfermedades. Cada sitio es una comuna, y son vecinas las que comparten frontera. El riesgo estimado en una comuna con pocos habitantes es muy inestable, y el modelo lo estabiliza compartiendo información con las comunas vecinas.
- Ecología. Cada sitio es una celda de una grilla en la que se registra la presencia o ausencia de una especie. La presencia en una celda depende de lo que ocurre en las celdas contiguas, lo que permite describir la dispersión.

Aplicación: digitalizar un documento



Para digitalizar un archivo hay que decidir en cada pixel si corresponde a tinta o a papel. Si el escaneo es de mala calidad, lo que llega es

$$y_s = x_s + \varepsilon_s, \qquad x_s \in \{-1, +1\}, \qquad \varepsilon_s \sim \mathcal{N}(0, \sigma^2),$$

con errores independientes entre pixeles. De esa decisión depende que el texto pueda leerse y que funcione el reconocimiento automático de caracteres.

Por qué conviene mirar a los vecinos

El ruido es independiente de un pixel a otro, mientras que la imagen verdadera es fuertemente dependiente, porque los pixeles vecinos casi siempre pertenecen a lo mismo, un trazo de tinta o el papel.

Esa asimetría es la que se explota. Un pixel aislado que contradice a todo su entorno es mucho más probablemente un error del escáner que un rasgo real del documento, de modo que el entorno sirve de segunda opinión sobre cada pixel.

Falta decir cómo se escribe esa segunda opinión, y ahí entra el modelo de Ising.

El problema como inferencia bayesiana

Lo desconocido es la imagen verdadera x y lo observado es el escaneo y.

- La distribución a priori $\mathbb{P}(x)$ es el modelo de Ising, que dice qué imágenes son plausibles antes de mirar los datos, favoreciendo las que tienen zonas homogéneas.
- La verosimilitud $\mathbb{P}(y \mid x)$ describe el escáner, y como el ruido es independiente entre pixeles, es un producto de densidades normales centradas en los valores verdaderos.

La regla de Bayes los combina en la distribución a posteriori,

$$\mathbb{P}(x \mid y) \;\propto\; \mathbb{P}(y \mid x)\,\mathbb{P}(x),$$

y la imagen se recupera buscando la configuración más probable a posteriori.

La regla local a posteriori

Al escribir el producto anterior, la condicional de un pixel dado el resto resulta ser la regla local de Ising con un término adicional, el que aporta el escaneo en ese mismo pixel,

$$\mathbb{P}(X_s = +1 \mid \text{vecinos}, y_s) = \frac{1}{1 + \exp\{-2(\underbrace{\beta \sum_{t \in N(s)} x_t}_{\text{previa de Ising}} + \underbrace{y_s/\sigma^2}_{\text{datos}})\}}.$$

El primer término viene de $\mathbb{P}(x)$ y el segundo de $\mathbb{P}(y \mid x)$. La distribución a posteriori es entonces otro campo de Markov, con los mismos vecinos, y por eso todo lo dicho sobre el modelo de Ising sigue sirviendo.

Con $\beta = 0$ la previa deja de informar y se vuelve a la decisión pixel a pixel.

Un pixel en detalle

valores observados y

-0,7	-0,3	-0,7	0,7	-1,6
-1,7	-1,9	-2,5	-3,6	0,1
-1,9	-1,0	1,5	-1,7	-1,2
-2,3	-0,3	-0,2	-2,4	0,2
1,5	-0,8	-1,4	-0,3	-1,3

decisión pixel a pixel

−1	−1	−1	+1	−1
−1	−1	−1	−1	+1
−1	−1	+1	−1	−1
−1	−1	−1	−1	+1
+1	−1	−1	−1	−1

Vecindario de 5×5 pixeles del escaneo, en una zona de papel. El pixel marcado se observó en $y_s = 1{,}5$, de modo que mirándolo solo se declara tinta y se comete un error, mientras que sus cuatro vecinos se observaron claramente negativos.

Qué tan fuerte tiene que ser el dato

El pixel se declara tinta cuando su valor observado supera un umbral que depende de los vecinos. Con $\beta = 0{,}6$ y $\sigma = 1{,}2$,

Vecinos en tinta	$\sum_{t \in N(s)} x_t$	Se declara tinta si
4	4	$y_s > -3{,}5$
3	2	$y_s > -1{,}7$
2	0	$y_s > 0$
1	-2	$y_s > 1{,}7$
0	-4	$y_s > 3{,}5$

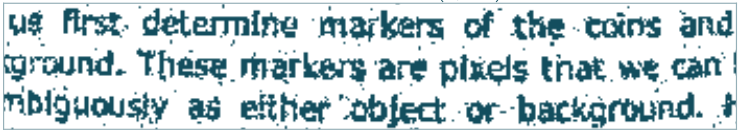
Decidir pixel a pixel equivale a exigir siempre $y_s > 0$. El pixel del ejemplo anterior, con $y_s = 1{,}5$ y los cuatro vecinos en papel, no alcanza el umbral 3,5 y se corrige.

Resultados

pixel a pixel (20,2%)



usando los vecinos (4,0%)



Mismo escaneo de la lámina anterior, con $\sigma = 1{,}2$ y $\beta = 0{,}6$. Respecto del documento original, el error pasa del 20,2% al 4,0% de los pixeles, y el texto vuelve a ser legible.